

Estimarea Complexitatii Lexicale folosind Date de Eye-Tracking

Dana Ioana Lepadat

ioana-dana.lepadat@unibuc.ro

Amalia Teodora Grebanus

amalia-teodora.grebanus@unibuc.ro

Abstract

In acest proiect s-a incercat estimarea complexitatea lexicala folosind date de eye-tracking. S-au testat mai multe metode, de la modele de machine learning precum LightGBM si CatBoost, pana la metode hibride bazate pe embeddings, modele Transformer si scoruri. Cea mai buna abordare s-a dovedit a fi combinarea directa a metricilor de eye-tracking, care a obtinut scorul 43.59/100.

1 Introducere

Complexitatea lexicala arata cat de dificil este un cuvânt pentru un cititor. Estimarea cuvintelor dificile poate fi utila in multe domenii, precum simplificarea textelor sau in educatie

Ipoteza proiectului a fost ca un cuvânt mai dificil cere mai mult efort la citire. Acest efort poate aparea in datele de eye-tracking prin timpi de citire mai mari, mai multe fixatii si timp de recitare mai mare.

Experimentele realizate au fost:

- E1 - CatBoost cu pseudo-labels si embeddings;
- E2 - LightGBM cu feature-ul has-eye;
- E3 - LightGBM antrenat pe un target generat de un LLM;
- E4 - metoda hibrida bazata pe eye-tracking, Transformer si proxy-uri de complexitate;
- E5 - agregarea statistica directa a metricilor de eye-tracking.

2 Abordare

2.1 Datele utilizate

Setul de date contine observatii de eye-tracking pentru cuvinte din texte in limba romana. Pentru fiecare cuvânt exista metrici care descriu modul in care participantii l-au citit.

Am folosit in principal metricile FFD, FPRT, TFT, RRT, TFC si skipped. Acestea masoara durata primei fixatii, timpul de citire, timpul total de fixare, timpul de recitare, numarul de fixatii si daca un cuvânt a fost sarit.

Aceste metrici sunt importante deoarece un cuvânt mai dificil poate avea timpi mai mari de citire si mai multe fixatii. In schimb, un cuvânt sarit este de obicei mai usor sau mai predictibil.

2.2 Preprocesare

Cuvintele au fost transformate sa aiba doar litere mici, au fost eliminate semnele de punctuatie de la inceputul si finalul cuvântului si au fost normalizate unele caractere romanesti. Dupa aceasta etapa, am grupat valorile obtinute pentru fiecare cuvânt in context, deoarece acelasi cuvânt putea fi citit de mai multi participanti. Astfel, am redus zgomotul produs de diferentele dintre cititori.

2.3 Experimentul 1

Primul experiment a folosit CatBoost, impreuna cu date de eye-tracking, frecventa cuvintelor, lungimea cuvintului si embeddings din modele precum Word2Vec, fastText, spaCy si XLM-RoBERTa.

Deoarece nu existau etichete reale de complexitate, am construit etichete estimate de model (pseudo-labels) pe baza acestor informatii.

Rezultatul obtinut a fost 24.35/100. Scorul a fost mai mic deoarece pseudo-labels nu au reprezentat suficient de bine complexitatea reala.

2.4 Experimentul 2

Al doilea experiment a folosit algoritmul LightGBM. Modelul nu a fost antrenat direct pe scorul real de complexitate, ci pe un scor estimat/generat de un LLM. S-au folosit caracteristici de eye-tracking, frecventa lexicala, informatii textuale si reprezentari extrase din modele de limbaj pre-antrenate.

Fata de o incercare anterioara foarte asemanatoare, in experiment am adaugat caracteristica *has_eye*. Aceasta indica daca pentru un cuvint exista date de eye-tracking. Scopul ei a fost sa ajute modelul sa trateze diferit exemplele cu date oculare fata de cele fara. Modelul a fost antrenat folosind 5-Fold Cross Validation si Early Stopping.

Rezultatul obtinut a fost 39.066/100.

2.5 Experimentul 3

Al treilea experiment a folosit aceeasi structura ca Experimentul 2: LightGBM, target generat de LLM si aceleasi tipuri de caracteristici.

Diferenta principala a fost calibrarea predictiilor finale. In loc de calibrare afina ($s_{nou} = a * s_{vechi} + b$), am folosit calibrare prin cuantile ($uncuvantesteintopx\%$ cele mai complexe din model), apoi shrinkage de $0.7(s_{final} = medie + 0.7 * (s_{calibrat} - medie))$. Astfel, au fost reduse valorile prea extreme si a produs predictii mai stabile. Modelul a fost antrenat folosind 5-Fold Cross Validation si Early Stopping.

Rezultatul obtinut a fost 39.079/100.

2.6 Experimentul 4

In acest experiment am folosit o metoda hibrida, care combina date de eye-tracking, informatii lexicale si semnale extrase din modele Transformer pentru limba romana.

Scorul obtinut a fost 40.78/100. Totusi, metoda depindea prea mult de un scor construit manual si de ponderi alese experimental, deci era mai greu de justificat ca solutie finala. Astfel, s-a decis sa nu fie inclusa in submissiile finale, desi avea un scor bun.

2.7 Experimentul 5

Ultimul experiment a folosit o metoda bazata pe reguli si agregarea directa a metricilor de eye-tracking. Cuvintele au fost normalizate, apoi datele au fost grupate dupa `text_name` si cuvintul normalizat.

Pentru metricile TFC, FFD, TRT, TFT, FPRT si RRT am calculat media, mediana, maximul si deviatia standard. Pentru metrica *skipped* am folosit doar media.

Scorul a fost construit manual: valorile mari ale timpilor de citire au crescut scorul, iar valoarea mare pentru *skipped* l-a sczut. Daca un cuvint din test nu avea potrivire directa, am folosit scorul mediu al aceluia cuvint, iar la final lungimea cuvintului ca fallback. Scorurile au fost normalizate in intervalul [0.01, 0.99] cu MinMaxScaler.

Acest experiment a obtinut scorul 43.59/100, fiind cel mai bun rezultat.

3 Tabele si grafice relevante




Figure 1: Compararea scorurilor obtinute de experimente.




Figure 2: Ponderile folosite pentru construirea scorului in Experimentul 5.




Figure 3: Distributia scorurilor finale generate de cea mai buna metoda.

Metrica	Semnificatie
FFD	Durata primei fixatii pe cuvant
FPRT	Timpul petrecut pe cuvant la prima citire
TFT	Timpul total de fixare pe cuvant
RRT	Timpul de recitare al cuvantului
TFC	Numarul total de fixatii pe cuvant
skipped	Indica daca un cuvant a fost sarit

Table 1: Metricile principale de eye-tracking folosite.

Rezultatele arata ca metoda bazata pe agregarea directa a statisticilor de eye-tracking a obtinut cea mai buna performanta. Acest lucru sugereaza ca, pentru acest set de date, semnalele oculare agregate au fost mai stabile si mai relevante decat targeturile estimate automat folosite de modelele mai complexe.

4 Limitari

Modelele LightGBM si CatBoost au fost mai complexe, dar nu au depasit metoda simpla. O posibila explicatie este faptul ca acestea au fost antrenate pe targeturi estimate automat, care pot contine zgomot. Din cauza complexitatii lor, modelele au putut invata nu doar relatiile utile, ci si variatiile accidentale din aceste targeturi, ceea ce consideram ca a dus la overfitting.

In final, metoda simpla bazata direct pe datele de eye-tracking a oferit cel mai bun rezultat.

5 Contributia autorilor

Proiectul a fost realizat in colaborare de Amalia-Teodora Grebanus si Dana-Ioana Lepadat. Fiecare a contribuit la testarea si evaluarea unor abordari diferite.

Amalia Teodora Grebanus

- implementarea si evaluarea modelelor CatBoost si LightGBM;
- construirea si testarea pseudo-etichetelor;
- integrarea caracteristicilor textuale, lexicale si de eye-tracking;
- dezvoltarea si compararea experimentelor E2, E3, E4.

Dana Ioana Lepadat

- preprocesarea datelor de eye-tracking;
- normalizarea cuvintelor si agregarea metricilor;
- construirea scorului bazat pe caracteristici oculare;
- dezvoltarea si evaluarea experimentului E5, avand cel mai bun scor.

Activitati realizate in colaborare

- interpretarea rezultatelor;
- dezvoltarea experimentului E1
- compararea experimentelor E1–E5;
- redactarea raportului final si formularea concluziilor.

6 Concluzie

In acest proiect am investigat utilizarea datelor de eye-tracking pentru estimarea complexitatii lexicale. Rezultatele obtinute sugereaza ca timpul total de citire, numarul de fixatii si timpul de recitare pot oferi indicii utile despre dificultatea unui cuvânt.

Cea mai buna performanta a fost obtinuta de metoda bazata pe agregarea directa a statisticilor de eye-tracking, care a atins scorul 43.59/100. Aceasta metoda simpla a depasit modelele mai complexe testate, precum LightGBM si CatBoost.

Acest rezultat indica faptul ca, in cazul acestui set de date, alegerea unor semnale relevante din datele de eye-tracking a fost mai importanta decat complexitatea algoritmului utilizat. Pentru lucrari viitoare, ar fi utila folosirea unui set mai mare de valori reale de complexitate lexicala si integrarea unor reprezentari contextuale mai robuste, obtinute cu modele Transformer.